

Assignment 2

Working with Data in Python: NumPy and Pandas

Максимальная оценка: 100 баллов | 4 задания × 25 баллов

Загрузить в Moodle до 03.10.2026 и защитить 09.02.2026

При загрузке отчета после 03.10.2026 – 20%

Защита после 09.02.2026 – 20%

Общие требования

- Работа выполняется в Jupyter Notebook (.ipynb). Все ячейки должны запускаться последовательно сверху вниз без ошибок (Run All).
- Для воспроизводимости случайных данных в начале заданий 1 и 2 установите seed, например `np.random.seed(42)` или используйте `np.random.default_rng(42)`.
- В заданиях 1–2 основные вычисления выполняются с NumPy. Не заменяйте векторизованные операции обычными циклами там, где задача решается средствами NumPy.
- В заданиях 3–4 используется Pandas. Для визуализации разрешены matplotlib и seaborn.
- После каждого смыслового блока выводите результат и добавляйте краткий комментарий: что было вычислено и что означает полученный результат.
- Названия переменных должны быть понятными. Не используйте имена вида `a`, `b`, `x1`, `x2` для основных данных.
- Перед сдачей удалите лишние тестовые ячейки, дублирующий код и ненужные выводы.
- На защите преподаватель может попросить объяснить любую строку кода, изменить условие фильтрации, выбрать другой срез или пересчитать показатель для другой группы.

Задание 1. NumPy: массивы, статистика и векторизация (25 баллов)

Контекст: необходимо смоделировать числовые характеристики 200 объявлений о продаже квартир и выполнить базовый анализ только средствами NumPy.

1.1. Подготовка и создание данных — 4 балла

1. Импортируйте NumPy и задайте фиксированный seed для генератора случайных чисел.
2. Создайте `area_array` — 200 значений площади квартир в диапазоне от 25 до 150 м². Значения могут быть целыми или вещественными.
3. Создайте `rooms_array` — 200 целых значений количества комнат от 1 до 5 включительно.
4. Создайте `price_array` — 200 значений стоимости квартир в диапазоне от 15 до 120 млн тенге.
5. Убедитесь, что все три массива имеют одинаковое количество элементов и соответствуют одним и тем же 200 квартирам.
6. Для каждого массива выведите `shape`, `ndim`, `size` и `dtype`.

Подсказка: Для генерации можно использовать `np.random.randint()`, `np.random.uniform()` или методы объекта `rng`. Значения `price_array` допускается округлить до 1–2 знаков.

Что должно быть в результате

- Три массива длиной 200.
- Вывод основных атрибутов каждого массива.

- Короткое пояснение, что означают `shape`, `ndim`, `size` и `dtype`.

1.2. Индексация, срезы и булева фильтрация — 5 баллов

1. Выведите первые 10 и последние 10 элементов каждого массива.
2. Выберите и выведите площади квартир с индексами от 20 до 39 включительно.
3. Найдите количество квартир площадью более 70 м².
4. Найдите квартиры со стоимостью выше среднего значения `price_array`. Выведите их количество и первые 10 найденных цен.
5. Создайте одну составную булеву маску для квартир, у которых `area > 70` и `rooms >= 3`. Выведите количество таких квартир.
6. Усложните условие: найдите квартиры с 2–4 комнатами, площадью 60–100 м² и стоимостью не выше 80 млн тенге. Выведите индексы первых 10 подходящих квартир.

Подсказка: Для составных условий используйте `&`, `|` и круглые скобки. Не используйте Python `and/or` для NumPy-массивов.

Что должно быть в результате

- Примеры обычной индексации и slicing.
- Не менее трёх булевых масок.
- Количество объектов, удовлетворяющих каждому условию.

1.3. Описательная статистика — 6 баллов

1. Для `area_array` и `price_array` вычислите `mean`, `median`, `min`, `max`, `standard deviation` и `variance`.
2. Для обоих массивов вычислите перцентили 10%, 25%, 50%, 75%, 90% и 99%.
3. Определите индекс самой дорогой квартиры. По этому индексу выведите её `price`, `area` и `rooms`.
4. Определите индекс квартиры с максимальной площадью и выведите все её характеристики.
5. Посчитайте, сколько квартир имеют цену ниже медианы и сколько — площадь выше среднего значения.
6. Сравните `mean` и `median` цены в 1–2 предложениях. Укажите, что может означать заметная разница между ними.

Подсказка: Понадобятся `np.mean`, `np.median`, `np.min`, `np.max`, `np.std`, `np.var`, `np.percentile`, `np.argmax`.

1.4. Векторизованные вычисления и новые признаки — 6 баллов

1. Создайте `price_per_m2_array` по формуле `price_array / area_array`. Цикл `for` для этого расчёта использовать нельзя.
2. Найдите среднюю, медианную, минимальную и максимальную цену за 1 м².
3. Определите индекс квартиры с максимальной ценой за 1 м² и выведите её исходные характеристики.
4. Посчитайте количество квартир, у которых цена за 1 м² выше среднего значения.
5. Создайте условную категорию `expensive_flag` как булев массив: `True`, если цена квартиры выше 75-го перцентиля `price_array`, иначе `False`.
6. Проверьте, сколько элементов `True` и `False` содержит `expensive_flag`.

Что должно быть в результате

- Массив `price_per_m2_array` длиной 200.
- Булев массив `expensive_flag`.
- Статистика по новому признаку без циклов.

1.5. Нормализация и краткий вывод — 4 балла

1. Нормализуйте `area_array` и `price_array` методом Min-Max в диапазон `[0, 1]`. Формулу реализуйте самостоятельно средствами NumPy.
2. Проверьте минимальное и максимальное значения нормализованных массивов.
3. Выведите первые 5 исходных и первые 5 нормализованных значений.
4. Напишите 2–3 предложения: зачем нужна нормализация и в каких задачах она может быть полезна.

Задание 2. NumPy: многомерные массивы и анализ тензора (25 баллов)

Контекст: имеются почасовые температуры для 3 городов за 7 дней. Данные представлены трёхмерным массивом NumPy.

2.1. Создание и исследование тензора — 4 балла

1. Создайте тензор `T` формы (7, 24, 3): ось 0 — дни, ось 1 — часы, ось 2 — города.
2. Заполните тензор случайными температурами от -10 до +35 °C.
3. Выведите `shape`, `ndim`, `size` и `dtype`.
4. Отдельно объясните, что обозначает каждая ось и чему равен `T.shape[0]`, `T.shape[1]`, `T.shape[2]`.

Что должно быть в результате

- Тензор формы (7, 24, 3).
- Корректное объяснение осей.

2.2. Индексация и срезы — 6 баллов

1. Выведите температуры второго города за все дни и все часы. Укажите форму полученного массива.
2. Выведите все данные первого дня для трёх городов. Укажите форму.
3. Получите одно значение: температура в 3-й день, в 12:00, во 2-м городе. Обратите внимание на индексацию с нуля.
4. Выведите температуры всех городов с 09:00 до 18:00 за всю неделю.
5. Выведите температуры первого города за выходные дни (6-й и 7-й дни).
6. Получите массив температур всех городов ровно в 08:00 за 7 дней и укажите его форму.

Подсказка: На защите будьте готовы объяснить, почему `T[:, :, 1]`, `T[0, :, :]` и `T[:, 8, :]` имеют разные формы.

2.3. Агрегирование по осям — 7 баллов

1. Найдите среднюю температуру по каждому городу за всю неделю.
2. Найдите минимальную и максимальную температуру для каждого города.
3. Для каждого дня найдите максимальную температуру среди всех часов и городов.
4. Для каждого дня вычислите среднюю температуру отдельно по каждому городу. Результат должен иметь форму (7, 3).
5. Определите час суток с минимальной средней температурой, усреднив значения по всем дням и городам.
6. Определите день с самой высокой средней температурой.
7. Определите город с самой высокой средней температурой за неделю.

Подсказка: В этом разделе важно правильно выбирать `axis`. В комментариях укажите, какие оси вы сворачиваете при каждом вычислении.

2.4. Изменение формы и проверка данных — 4 балла

1. Преобразуйте T из формы (7, 24, 3) в матрицу формы (7, 72).
2. Объясните, что теперь находится в одной строке новой матрицы.
3. Верните матрицу обратно к форме (7, 24, 3).
4. Проверьте, совпадают ли исходный и восстановленный тензоры с помощью `np.array_equal()` или `np.allclose()`.

2.5. Сравнение городов и интерпретация — 4 балла

1. Преобразуйте данные каждого города в последовательность из 168 температур (7×24).
2. Постройте корреляционную матрицу 3×3 с помощью `np.corrcoef`.
3. Не учитывая диагональ, определите пару городов с наибольшим коэффициентом корреляции.
4. Напишите 2–3 предложения, что означает положительная, отрицательная и близкая к нулю корреляция в контексте температур.

Задание 3. Pandas: загрузка, очистка и подготовка данных (25 баллов)

Контекст: работа с датасетом объявлений о продаже квартир. Используйте CSV-файлы или единый CSV-файл, выданный преподавателем.

3.1. Загрузка и первичное исследование — 4 балла

1. Импортируйте `pandas`, `numpy` и необходимые библиотеки для визуализации.
2. Если преподаватель выдал несколько CSV-файлов, прочитайте их и объедините в один `DataFrame` с помощью `pd.concat(..., ignore_index=True)`. Если выдан один файл — просто загрузите его.
3. Выведите первые 5 и последние 5 строк `DataFrame`.
4. Выведите `df.shape`, `df.columns`, `df.dtypes`, `df.info()` и `df.describe(include="all")`.
5. В 2–3 предложениях опишите размер датасета и типы содержащихся признаков.

3.2. Проверка и обработка дубликатов — 4 балла

1. Посчитайте количество полных дубликатов строк с помощью `df.duplicated().sum()`.
2. Выведите несколько найденных дубликатов, если они существуют.
3. Проверьте дубликаты по логически важным колонкам. Например: ID + Price, Address + Price или другая комбинация, соответствующая вашему датасету.
4. Примите решение: нужно ли удалять дубликаты. Обязательно объясните решение.
5. Если дубликаты удаляются, покажите количество строк до и после удаления.

Подсказка: Не удаляйте строки автоматически только потому, что `duplicated()` вернул `True`. Сначала объясните, почему строки действительно считаются повторными объявлениями.

3.3. Пропущенные значения — 6 баллов

1. Посчитайте пропуски по каждой колонке: количество и долю в процентах.
2. Отсортируйте колонки по количеству пропусков по убыванию.
3. Выберите не менее трёх колонок с пропусками и для каждой предложите способ обработки.
4. Для числовой колонки примените `median` или `group-based imputation`, если это обосновано.
5. Для категориальной колонки примените `mode` или заполнение отдельной категорией, если это обосновано.
6. Если какая-либо колонка имеет слишком много пропусков, можно обосновать её удаление. Необходимо указать причину.
7. После обработки повторно выведите таблицу пропущенных значений.

Что должно быть в результате

- Таблица/Series с числом и процентом пропусков.
- Обоснование выбранного метода заполнения для каждой обработанной колонки.
- Проверка после очистки.

3.4. Типы данных и преобразования — 4 балла

1. Определите колонки, которые должны быть числовыми, но имеют dtype object.
2. Очистите текстовые символы, пробелы или единицы измерения, мешающие преобразованию, если они есть.
3. Преобразуйте такие колонки с помощью `pd.to_numeric(..., errors="coerce")`.
4. Если имеется колонка с датой, преобразуйте её в datetime с помощью `pd.to_datetime()`.
5. После преобразований снова выведите dtypes и проверьте, не появились ли новые NaN.

3.5. Переименование колонок и feature engineering — 5 баллов

1. Переименуйте длинные названия колонок в короткие, единообразные и понятные имена.
2. Создайте `price_per_m2 = price / area`. Предварительно убедитесь, что area не содержит нулевых значений.
3. Создайте `floor_category`, например: first / middle / last. Если структура данных другая, допускается эквивалентный категориальный признак.
4. Создайте ещё минимум один содержательный признак: `area_category`, `price_category`, `room_area_ratio`, `building_age` или другой признак, который можно получить из существующих данных.
5. Для каждого нового признака напишите короткое объяснение его смысла.

3.6. Сохранение и контроль качества — 2 балла

1. Сохраните очищенный DataFrame в `apartments_clean.csv` без индекса.
2. Снова прочитайте сохранённый файл в новый DataFrame и сравните shape с исходным очищенным DataFrame.
3. Выведите первые 3 строки сохранённого файла как подтверждение.

Задание 4. Pandas: анализ, группировка и визуализация (25 баллов)

Используйте только очищенный DataFrame из Задания 3. Цель — получить содержательные аналитические выводы, а не только построить графики.

4.1. Описательная статистика и фильтрация — 5 баллов

1. Выведите `describe()` для числовых колонок.
2. Найдите 5 самых дорогих квартир и выведите не менее четырёх информативных колонок для них.
3. Найдите 5 квартир с минимальной ценой за 1 м².
4. Сформируйте фильтр с двумя условиями, например `rooms >= 3` и `area > 80`. Выведите количество строк и первые найденные записи.
5. Сформируйте ещё один фильтр с тремя условиями по своему выбору и объясните, какой тип квартиры он выделяет.

4.2. GroupBy и агрегирование — 7 баллов

1. Вычислите среднюю и медианную цену по количеству комнат.
2. Вычислите среднюю цену за 1 м² по району или жилому комплексу. Отсортируйте результат по убыванию.

3. Для выбранной категориальной колонки выполните `groupby().agg()` и получите `count`, `mean`, `median`, `min`, `max` по цене.
4. Найдите группу с максимальной средней ценой и группу с минимальной средней ценой.
5. Создайте `pivot_table` по двум категориальным признакам, если соответствующие колонки присутствуют. Например: строки — район, столбцы — количество комнат, значения — средняя цена.
6. Напишите минимум два вывода на основе группировок.

Подсказка: Если в вашем датасете нет района или жилого комплекса, выберите другую содержательную категориальную колонку и укажите это в Notebook.

4.3. Визуализация — 8 баллов

1. Постройте bar chart средней цены по количеству комнат.
2. Постройте scatter plot зависимости цены от площади.
3. Постройте boxplot распределения цены по количеству комнат или по другой подходящей категории.
4. Постройте histogram для `price_per_m2` или `price`.
5. Постройте heatmap корреляционной матрицы числовых признаков.
6. Каждый график должен иметь title, подписи осей и читаемый размер. Для графиков с категориями при необходимости поверните подписи по оси X.

Что должно быть в результате

- Не менее пяти графиков.
- У каждого графика есть заголовок и подписи осей.
- После каждого графика — 1–2 предложения с интерпретацией.

4.4. Корреляционный анализ и итоговые выводы — 5 баллов

1. Выберите из корреляционной матрицы признаки, наиболее сильно связанные с `price`. Укажите коэффициенты.
2. Отдельно укажите один признак с положительной и один с отрицательной корреляцией, если такие присутствуют.
3. Не делайте вывод о причинности только на основе корреляции.
4. Сформулируйте минимум 5 содержательных выводов по всей работе с Pandas. Минимум два вывода должны основываться на группировках и минимум два — на визуализациях или корреляции.

Что необходимо сдать

- Один Jupyter Notebook (.ipynb) со всеми четырьмя выполненными заданиями.
- Файл `apartments_clean.csv`, полученный после Задания 3.
- Все таблицы и графики должны отображаться внутри Notebook после Run All.
- В конце Notebook должен быть раздел Conclusions с краткими выводами по заданиям 1–4.
- Перед загрузкой проверьте, что Notebook открывается и выполняется без обращения к абсолютным путям на вашем компьютере.

Критерии оценивания

Компонент	Что оценивается	Баллы
-----------	-----------------	-------

Задание 1	Корректные NumPy-массивы, индексация, булевы маски, статистика, векторизация и нормализация	25
Задание 2	Работа с 3D-массивом, slicing, axis, агрегирование, reshape и correlation	25
Задание 3	Загрузка, дубликаты, пропуски, типы данных, feature engineering и сохранение	25
Задание 4	Фильтрация, GroupBy/Pivot, визуализация, корреляционный анализ и выводы	25
Итого		100

Контрольные вопросы для защиты

Важно: вопросы не обязательно будут заданы в таком же порядке. Преподаватель может попросить объяснить код, изменить конкретное условие или выполнить небольшой фрагмент анализа во время защиты.

A. NumPy

1. Чем NumPy array отличается от обычного Python list?
2. Что обозначают атрибуты shape, ndim, size и dtype?
3. Почему массивы NumPy обычно эффективнее списков Python для числовых вычислений?
4. Что такое векторизация? Приведите пример из вашего Задания 1.
5. Что такое broadcasting в NumPy и когда он используется?
6. Чем обычная индексация отличается от slicing?
7. Что вернёт выражение arr[10:20] и включается ли индекс 20?
8. Как получить последние 10 элементов одномерного массива?
9. Что такое булева маска и какого типа элементы она содержит?
10. Почему для объединения условий по NumPy-массивам используют & и |, а не and и or?
11. Как одновременно отфильтровать квартиры по площади, числу комнат и цене?
12. Чем np.mean() отличается от np.median()? В каком случае median может быть информативнее?
13. Что показывает стандартное отклонение?
14. Чем variance связана со standard deviation?
15. Что такое перцентиль? Что означает 75-й перцентиль цены?
16. Для чего используется np.argmax()? Что именно он возвращает?
17. Почему price_per_m2_array можно вычислить без цикла?
18. Что означает Min-Max normalization и в каком диапазоне будут значения?
19. Что произойдёт при Min-Max нормализации, если max == min?
20. Что такое многомерный массив или тензор?
21. Что означают три оси тензора T формы (7, 24, 3)?
22. Какой результат и какую форму даст T[:, :, 1]?
23. Какой результат и какую форму даст T[0, :, :]?
24. Как получить температуры всех городов в 8:00 за все дни?
25. Что означает параметр axis в функциях np.mean(), np.max() и np.min()?
26. Какие оси нужно усреднить, чтобы получить одну среднюю температуру для каждого города?

27. Как получить матрицу формы (7, 3), содержащую среднюю температуру каждого города по каждому дню?
28. Чем `reshape()` отличается от `transpose()`?
29. Почему после `reshape(7, 72)` количество элементов не меняется?
30. Для чего можно использовать `np.array_equal()` или `np.allclose()`?
31. Что измеряет коэффициент корреляции?
32. В каком диапазоне находится коэффициент корреляции?
33. Что означает корреляция, близкая к +1, -1 и 0?
34. Почему высокая корреляция не доказывает причинно-следственную связь?

B. Pandas

1. Что такое Series и DataFrame? В чём их различие?
2. Для чего используются `head()`, `tail()`, `shape`, `columns` и `dtypes`?
3. Какую информацию показывает `df.info()`?
4. Чем `df.describe()` отличается от `df.info()`?
5. Для чего используется `pd.concat()` и зачем может понадобиться `ignore_index=True`?
6. Что такое полный дубликат строки?
7. Чем `duplicated()` отличается от `drop_duplicates()`?
8. Почему дубликаты нельзя всегда удалять автоматически?
9. Как проверить дубликаты только по выбранным колонкам?
10. Как определить количество пропущенных значений в каждой колонке?
11. Как вычислить процент пропусков по колонкам?
12. В чём разница между `dropna()` и `fillna()`?
13. Когда разумно заполнять числовые пропуски средним, а когда медианой?
14. Когда для категориального признака подходит `mode`?
15. Что такое group-based imputation и почему она иногда лучше общего среднего?
16. Что делает `pd.to_numeric(errors="coerce")`?
17. Зачем использовать `pd.to_datetime()`?
18. Почему после преобразования типов необходимо снова проверить NaN?
19. Как переименовать одну или несколько колонок в Pandas?
20. Что такое feature engineering? Назовите признаки, созданные вами в Задании 3.
21. Почему перед вычислением `price_per_m2` нужно проверить нулевые площади?
22. Для чего используется `loc[]` и чем он отличается от `iloc[]`?
23. Как отфильтровать строки DataFrame сразу по нескольким условиям?
24. Что делает `sort_values()`?
25. Что делает `groupby()` и из каких основных этапов состоит операция split-apply-combine?
26. Чем `agg()` полезнее одиночного `mean()` после `groupby()`?
27. Что такое `pivot_table` и чем она отличается от обычного `groupby()`?
28. Что показывает `count` в агрегированной таблице и почему он важен при сравнении групп?
29. Почему среднее значение группы с очень малым `count` нужно интерпретировать осторожно?
30. Для чего нужны bar chart, scatter plot, boxplot и histogram? Какую информацию показывает каждый?
31. Что можно увидеть на scatter plot зависимости `price` от `area`?
32. Что показывает boxplot и что такое выбросы?
33. Что показывает histogram?
34. Что представляет собой корреляционная матрица?

35. Почему в heatmap корреляции диагональные значения равны 1?
36. Можно ли применять корреляцию Пирсона к произвольным текстовым колонкам? Почему?
37. Почему корреляция сама по себе не означает причинность?
38. Как сохранить DataFrame в CSV без дополнительного столбца индекса?
39. Как проверить, что сохранённый CSV прочитался корректно?
40. Чем merge(), join() и concat() отличаются по назначению?
41. Что произойдёт, если применить groupby к колонке, содержащей NaN?
42. Как найти 5 строк с максимальными или минимальными значениями определённого признака?
43. Какие основные проблемы качества данных вы обнаружили в своём датасете?
44. Какое преобразование данных в вашей работе сильнее всего повлияло на итоговый анализ и почему?