Assignment № 3. Обработка естественного языка (NLP)

Срок сдачи: загрузить работу в Moodle и пройти защиту до 24.10.2026.

Штраф за несвоевременную сдачу: при загрузке и защите задания после установленного срока из каждого задания вычитается 20%. Таким образом, при выполнении всех заданий максимальный балл составляет 80 из 100.

Общие требования

Студенты должны реализовать, оценить и сравнить методы обработки естественного языка (Natural Language Processing, NLP) с использованием Python.

Рекомендуемые библиотеки: NLTK, spaCy, scikit-learn, pandas, NumPy, Matplotlib, Seaborn, Hugging Face Transformers и PyTorch.

Все студенты должны:

1. Использовать подходящие наборы данных и описать их характеристики.
2. Выполнить предварительную обработку текстов и обосновать выбранные методы.
3. Реализовать необходимые методы NLP.
4. Сравнить как минимум два подхода в каждом задании.
5. Оценить качество моделей с использованием соответствующих количественных метрик.
6. Визуализировать и интерпретировать экспериментальные результаты.
7. Провести анализ ошибок и предложить возможные улучшения.
8. Представить выводы, подтверждённые экспериментальными результатами.

Для обеспечения воспроизводимости экспериментов необходимо указать источник данных, значение случайного зерна (random seed), конфигурации моделей и используемые библиотеки. Следует исключить утечку данных (data leakage) между обучающей, валидационной и тестовой выборками.

Задание 1. Разработка и сравнительная оценка моделей анализа тональности текста (25 баллов)

Постановка задачи

Разработать систему анализа тональности (Sentiment Analysis), которая автоматически классифицирует текст по эмоциональной окраске.

Входные данные: предложение или отзыв пользователя.

Выходные данные: предсказанная категория тональности: отрицательная (negative), нейтральная (neutral) или положительная (positive).

Необходимо реализовать и сравнить три подхода:

1. Анализ тональности на основе словаря (Lexicon-based Sentiment Analysis).
2. Традиционное машинное обучение с использованием TF-IDF и Logistic Regression или Naive Bayes.
3. Классификация тональности с использованием предварительно обученной Transformer-модели.

Шаг 1. Подготовка набора данных

- Выбрать размеченный набор данных для анализа тональности, содержащий три класса (например, подходящий набор отзывов Amazon, TweetEval Sentiment или другой датасет с отрицательными, нейтральными и положительными метками).
- Использовать не менее 3 000 размеченных текстов, включая минимум 500 примеров каждого класса.
- Проанализировать распределение классов тональности.
- Удалить дублирующиеся записи, которые могут привести к утечке данных.
- Разделить набор данных на обучающую (70%), валидационную (15%) и тестовую (15%) выборки, применяя стратификацию при необходимости.

Шаг 2. Предварительная обработка текста

Реализовать и сравнить подходящие методы предварительной обработки:

- Токенизация (Tokenization).
- Приведение текста к нижнему регистру.
- Удаление несущественных символов.
- Удаление стоп-слов (Stopword Removal), если это целесообразно.
- Лемматизация (Lemmatization).

Объяснить, почему чрезмерная предварительная обработка может отрицательно влиять на словарные методы и Transformer-модели, особенно при удалении отрицаний или других признаков эмоциональной окраски.

Шаг 3. Анализ тональности на основе словаря

- Реализовать классификатор тональности с использованием VADER или подходящего словаря эмоционально окрашенных слов.
- Рассчитать оценки тональности (Sentiment Scores).
- Классифицировать тексты по трём категориям тональности.
- При необходимости настройки пороговых значений использовать только валидационную выборку.
- Оценить качество полученных предсказаний.

Шаг 4. Модель машинного обучения

- Преобразовать тексты в числовые векторы с помощью TF-IDF.
- Обучить классификатор Logistic Regression или Multinomial Naive Bayes.
- Проверить не менее двух конфигураций гиперпараметров.
- Оценить модель на валидационной выборке и выбрать лучшую конфигурацию.

Шаг 5. Модель на основе Transformer

- Выбрать предварительно обученную Transformer-модель для анализа тональности из Hugging Face, поддерживающую язык выбранного датасета и три целевых класса.
- Применить модель к тестовой выборке без дополнительного дообучения.
- При необходимости привести выходные метки модели к меткам используемого набора данных.
- Сравнить результаты с традиционными подходами.

Дообучение Transformer-модели (Fine-tuning) является необязательным.

Шаг 6. Оценка качества моделей

Рассчитать следующие метрики:

- Accuracy — точность классификации.
- Precision (macro) — макроусреднённая точность положительных предсказаний.
- Recall (macro) — макроусреднённая полнота.
- F1-score (macro) — макроусреднённая F1-мера.
- Confusion Matrix — матрица ошибок классификации.

Построить сравнительную таблицу с результатами оценки всех трёх подходов.

Шаг 7. Анализ ошибок

- Найти не менее пяти неправильно классифицированных отзывов.
- Сравнить предсказания различных моделей.
- Объяснить возможные причины ошибок: отрицания, сарказм, многозначность слов и предметно-специфические выражения.
- Определить наиболее эффективный подход и обосновать вывод экспериментальными результатами.

Исследовательский вопрос: обеспечивают ли предварительно обученные Transformer-модели существенное улучшение качества анализа тональности по сравнению со словарными методами и традиционным машинным обучением на выбранном наборе данных?

Критерии оценивания (25 баллов)

- Подготовка данных и предварительная обработка — 4 балла.
- Словарная модель — 4 балла.
- Модель машинного обучения — 5 баллов.
- Transformer-модель — 4 балла.
- Оценка качества и сравнение моделей — 4 балла.
- Анализ ошибок и устная защита — 4 балла.

Задание 2. Разработка и оценка методов автоматического суммирования текста (25 баллов)

Постановка задачи

Разработать и сравнить экстрактивный и абстрактивный подходы к автоматическому суммированию текста (Text Summarization).

Входные данные: пять англоязычных текстовых документов по взаимосвязанной тематике.

Выходные данные:

1. Экстрактивное резюме, содержащее по три наиболее важных предложения из каждого документа.
2. Объединённое экстрактивное резюме из шести предложений, выбранных из пятнадцати ранее извлечённых.
3. Абстрактивное резюме объёмом примерно 100–150 слов, охватывающее содержание всех пяти документов.

Цель задания — сравнить традиционные методы выбора значимых предложений с генерацией текста на основе Transformer-моделей.

Шаг 1. Сбор данных

- Выбрать пять тематически связанных документов, предпочтительно новостных статей, научных аннотаций или технических отчётов.
- Каждый документ должен содержать не менее 250 слов.
- Указать источник и количество слов для каждого документа.
- Подготовить краткое эталонное резюме объёмом 100–150 слов, написанное человеком, либо использовать датасет с подходящими эталонными резюме.

Эталонное резюме должно быть подготовлено независимо от автоматических методов, качество которых оценивается.

Шаг 2. Предварительная обработка текста

- Выполнить токенизацию на уровне предложений.
- Удалить лишние пробелы и символы форматирования.
- Применить подходящую предварительную обработку для расчёта значимости предложений.
- Сохранить исходные предложения для формирования итоговых резюме.

Шаг 3. Экстрактивное суммирование

Реализовать экстрактивный подход с использованием оценки значимости предложений на основе TF-IDF или TextRank.

- Рассчитать показатели значимости предложений.
- Выбрать три наиболее значимых предложения из каждого документа.
- Объединить пятнадцать выбранных предложений в один набор кандидатов.

- Выбрать шесть предложений для итогового объединённого резюме.
- Сохранить исходные формулировки и расположить предложения в логичном, удобном для чтения порядке.

Шаг 4. Абстрактивное суммирование

Использовать предварительно обученную Transformer-модель, например BART или T5.

- Сгенерировать резюме объёмом примерно 100–150 слов.
- Учесть ограничения модели по длине входного текста, применив подходящую стратегию, например разбиение текста на фрагменты (Chunking) или иерархическое суммирование.
- Зафиксировать параметры генерации.
- Проверить, насколько корректно сформированное резюме отражает информацию исходных документов.

Обучать новую языковую модель с нуля не требуется.

Шаг 5. Количественная оценка качества

Оценить итоговые экстрактивное и абстрактивное резюме относительно одного и того же эталонного резюме с использованием:

- ROUGE-1.
- ROUGE-2.
- ROUGE-L.

Представить результаты в сравнительной таблице.

Шаг 6. Качественный анализ

Оценить оба резюме по следующим критериям:

- Полнота охвата информации.
- Связность и читаемость.
- Избыточность информации.
- Фактическая согласованность с исходными документами.
- Грамматическая корректность.

Определить не менее трёх различий между экстрактивным и абстрактивным суммированием.

Рассмотреть как минимум один пример, в котором абстрактивная модель изменяет, пропускает или добавляет информацию.

Исследовательский вопрос: какой подход к суммированию обеспечивает лучший баланс между полнотой информации, читаемостью и фактической достоверностью?

Критерии оценивания (25 баллов)

- Сбор документов и предварительная обработка — 4 балла.
- Экстрактивное суммирование — 5 баллов.
- Абстрактивное суммирование — 5 баллов.

- Оценка ROUGE и сравнение — 5 баллов.
- Качественный анализ и устная защита — 6 баллов.

Задание 3. Лексический анализ и автоматическая классификация музыкальных жанров на основе текстов песен (25 баллов)

Постановка задачи

Исследовать лингвистические различия между музыкальными жанрами и разработать модель машинного обучения для определения жанра по тексту песни.

Входные данные: тексты песен, относящиеся к четырём музыкальным жанрам.

Выходные данные:

1. Сравнительный лексический анализ выбранных жанров.
2. Определение частотных, редких и тематических слов.
3. Автоматическая классификация музыкальных жанров.
4. Количественная оценка качества классификационных моделей.

Шаг 1. Сбор данных

- Выбрать датасет, содержащий тексты песен и метки музыкальных жанров.
- Выбрать четыре жанра, например Pop, Rock, Hip-Hop и Country.
- Использовать не менее 100 песен каждого жанра (минимум 400 песен).
- Использовать один язык для всего корпуса, предпочтительно английский.
- Удалить дублирующиеся тексты песен.
- Проанализировать распределение длины текстов и количество песен по жанрам.

Возможные источники данных: датасеты текстов песен на Kaggle или другие наборы данных, распространяемые на условиях соответствующих лицензий.

Шаг 2. Предварительная обработка текста

Реализовать:

- Приведение текста к нижнему регистру.
- Токенизацию.
- Удаление знаков препинания и ненужных символов.
- Удаление стоп-слов.
- Лемматизацию.

Объяснить влияние предварительной обработки на лексические характеристики текстов песен.

Шаг 3. Частотный анализ

Для каждого жанра:

- Определить 10 наиболее часто встречающихся слов.
- Рассчитать их абсолютные и относительные частоты.
- Визуализировать результаты с помощью столбчатых диаграмм.
- Сравнить особенности словарного состава различных жанров.

Шаг 4. Анализ лексических категорий

Создать словари минимум для трёх лексических категорий, например:

- Временные выражения: morning, evening, night.
- Эмоции: love, sadness, happiness, anger.
- Части тела: heart, eyes, hands.

Рассчитать частоты слов каждой категории для каждого жанра.

Нормализовать частоты категорий по общему количеству слов соответствующего жанра, чтобы обеспечить корректность сравнения.

Шаг 5. Редкие и характерные слова

- Найти слова, встречающиеся не более трёх раз в пределах каждого жанра.
- Рассчитать показатели TF-IDF для определения характерных слов различных жанров.
- Сравнить редкие слова со словами, имеющими высокие значения TF-IDF.
- Объяснить, почему редкие слова не всегда являются наиболее информативными признаками для определения музыкального жанра.

Шаг 6. Автоматическая классификация жанров

Разработать два подхода:

Модель 1: TF-IDF + Multinomial Naive Bayes.

Модель 2: TF-IDF + Logistic Regression.

- Разделить данные на обучающую (80%) и тестовую (20%) выборки с использованием стратификации.
- Обучать TF-IDF-преобразователь только на обучающей выборке.
- При наличии информации об исполнителях рассмотреть разделение данных по исполнителям для исследования потенциальной утечки данных.
- Обучить обе классификационные модели.

Шаг 7. Оценка и сравнение результатов

Рассчитать:

- Accuracy.
- Macro F1-score.
- Confusion Matrix.

Сравнить эффективность двух моделей.

Проанализировать не менее пяти ошибочных предсказаний и объяснить, какие музыкальные жанры чаще всего путаются.

Обсудить, достаточно ли только текстов песен для определения музыкального жанра, учитывая такие музыкальные характеристики, как ритм, инструменты и особенности вокала.

Исследовательский вопрос: позволяют ли лексические признаки и TF-IDF-представления различать музыкальные жанры и какие лингвистические характеристики оказывают наибольшее влияние на качество классификации?

Критерии оценивания (25 баллов)

- Подготовка данных и предварительная обработка — 4 балла.
- Частотный анализ и анализ лексических категорий — 5 баллов.
- Анализ редких слов и TF-IDF — 4 балла.
- Классификация с использованием машинного обучения — 5 баллов.
- Оценка, интерпретация и устная защита — 7 баллов.

Задание 4. Многоязычная идентификация языка и анализ устойчивости моделей (25 баллов)

Постановка задачи

Разработать систему автоматического определения языка текста и исследовать влияние длины текста, предварительной обработки и шума на точность классификации.

Входные данные: короткий текст, содержащий одно слово, одно предложение или несколько предложений.

Выходные данные: предсказанная метка языка и, при необходимости, оценка уверенности модели (Confidence Score).

Система должна распознавать от шести до восьми языков, включая казахский и русский.

Шаг 1. Подготовка набора данных

- Использовать готовый многоязычный датасет, например Tatoeba или WiLI-2018.
- Выбрать от шести до восьми языков, включая казахский, русский и английский.
- Добавить как минимум одну пару близкородственных языков, например испанский и португальский.
- Собрать не менее 500 текстовых примеров для каждого языка.
- Удалить полные дубликаты.
- Разделить датасет на обучающую (80%) и тестовую (20%) выборки.

Шаг 2. Эксперимент с предварительной обработкой

Сравнить две стратегии предварительной обработки.

Подход A — Интенсивная предварительная обработка:

- Привести тексты к нижнему регистру.
- Удалить цифры.
- Удалить знаки препинания и специальные символы.

Подход B — Минимальная предварительная обработка:

- Сохранить символы, характерные для отдельных языков.
- Удалить только лишние пробелы и артефакты форматирования.

Объяснить влияние предварительной обработки на распознавание казахского и других языков, содержащих специфические символы.

Важно: оба подхода должны сохранять допустимые буквы Unicode. Не допускается удаление специфических букв казахского языка, таких как ә, ғ, қ, ң, ө, ұ, ү, h и i.

Шаг 3. Представление текстовых признаков

Реализовать два способа представления текста:

1. TF-IDF на уровне слов (Word-level TF-IDF).
2. TF-IDF на уровне символов с использованием символьных n-грамм (1–3).

Сравнить эффективность обоих подходов для задачи идентификации языка.

Шаг 4. Разработка моделей

Обучить следующие классификаторы:

- Multinomial Naive Bayes.
- Logistic Regression.

Сравнить обученные модели с предварительно обученной системой определения языка, например fastText lid.176.

Предварительно обученную модель необходимо оценивать на той же отложенной тестовой выборке.

Шаг 5. Оценка качества моделей

Рассчитать:

- Accuracy.
- Macro F1-score.
- Confusion Matrix.

Сравнить результаты для различных стратегий предварительной обработки, способов представления признаков и моделей классификации.

Определить наиболее эффективную конфигурацию.

Шаг 6. Тестирование устойчивости модели (Robustness Testing)

Исследовать поведение модели в трёх условиях.

Эксперимент A — Короткие тексты

Сравнить качество определения языка для текстов различной длины:

- 1–3 слова.
- 4–10 слов.
- Более 10 слов.

Эксперимент B — Тексты с ошибками

Создать модифицированную версию тестовой выборки, добавив контролируемые орфографические ошибки, например:

- Удаление символов.
- Вставка дополнительных символов.
- Замена символов.

Сравнить качество классификации до и после внесения ошибок.

Эксперимент C — Смешение языков (Code-Switching)

- Составить не менее 30 предложений со смешением казахского и русского языков.
- Проанализировать предсказания обученной модели для смешанных текстов.
- Объяснить, почему классификатор с одной языковой меткой может некорректно обрабатывать смешение языков.

Данный эксперимент носит качественный характер. Его результаты не следует интерпретировать как стандартную точность одноязыковой классификации без явно определённой политики разметки.

Шаг 7. Анализ ошибок

- Найти не менее пяти неправильных предсказаний.
- Проанализировать влияние длины текста, общей лексики, орфографических ошибок и близкородственных языков.
- Объяснить, почему символьные признаки могут превосходить признаки на уровне слов при обработке коротких многоязычных текстов.
- Предложить способы повышения надёжности систем автоматического определения языка.

Исследовательский вопрос: как представление признаков, предварительная обработка и качество текста влияют на эффективность многоязычной идентификации, особенно для казахского и русского языков?

Критерии оценивания (25 баллов)

- Подготовка данных и эксперименты с предварительной обработкой — 4 балла.
- Формирование признаков — 4 балла.

- Реализация и сравнение моделей — 5 баллов.
- Количественная оценка — 4 балла.
- Тестирование устойчивости — 5 баллов.
- Анализ ошибок и устная защита — 3 балла.

Требования к сдаче задания

Каждый студент должен представить следующие материалы.

1. Jupyter Notebook (.ipynb)

Ноутбук должен содержать:

- Загрузку данных и предварительную обработку.
- Реализацию всех необходимых моделей.
- Обучение моделей и получение предсказаний.
- Расчёт метрик оценки качества.
- Визуализации.
- Экспериментальные результаты.
- Письменную интерпретацию полученных результатов.

Весь программный код должен быть исполняемым и иметь понятную, логичную структуру.

2. Устная защита

Студенты должны быть готовы:

- Объяснить реализованные методы обработки естественного языка.
- Обосновать выбор методов предварительной обработки и представления признаков.
- Интерпретировать метрики качества.
- Сравнить эффективность моделей.
- Объяснить экспериментальные результаты и ограничения использованных подходов.
- Продемонстрировать работу программного кода.

Разрешается использовать библиотеки, документацию и инструменты разработки с поддержкой искусственного интеллекта. Однако студенты обязаны понимать, проверять и уметь объяснять весь представленный код и экспериментальные результаты.

Результаты, сгенерированные искусственным интеллектом, не допускается представлять как фактические экспериментальные данные без реального выполнения вычислений и проверки.

Контрольные вопросы

1. В чём заключаются основные различия между словарными методами, традиционным машинным обучением и Transformer-подходами в NLP?
2. Каким образом TF-IDF представляет текстовую информацию?
3. Почему важно разделять данные на обучающую, валидационную и тестовую выборки?
4. Чем Macro F1-score отличается от Accuracy?

5. Какую информацию предоставляет матрица ошибок (Confusion Matrix)?
6. Как токенизация влияет на последующие задачи обработки естественного языка?
7. Почему удаление стоп-слов может ухудшить качество анализа тональности?
8. В чём разница между экстрактивным и абстрактивным суммированием текста?
9. Как алгоритм TextRank определяет наиболее важные предложения?
10. Что измеряют метрики ROUGE-1, ROUGE-2 и ROUGE-L?
11. Что такое галлюцинации (Hallucinations) при абстрактивном суммировании?
12. Почему при оценке абстрактивных резюме необходимо проверять фактическую согласованность?
13. В чём разница между частотой слова и показателем TF-IDF?
14. Почему размер набора данных имеет значение для классификации текста?
15. Как дисбаланс классов влияет на качество классификации?
16. Что такое символьные n-граммы и почему они полезны при идентификации языка?
17. Как специфические символы различных языков влияют на многоязычную классификацию?
18. Почему модели определения языка испытывают трудности при обработке коротких текстов?
19. Что такое Code-Switching и почему смешение языков представляет сложность для NLP-систем?
20. Как шум и орфографические ошибки влияют на точность классификации?
21. Что такое утечка данных (Data Leakage) и как она может повлиять на NLP-эксперименты?
22. Каковы преимущества и ограничения предварительно обученных Transformer-моделей?
23. Почему для оценки NLP-моделей необходимо использовать несколько метрик?
24. Какую информацию анализ ошибок может предоставить сверх агрегированных метрик качества?
25. Каким образом можно повысить воспроизводимость экспериментов в области обработки естественного языка?